

1. **분석할 데이터에 대해 설명하고, 해당 데이터 분석의 목적을 서술하시오.**

데이터 설명: 본 과제에서 분석할 데이터는 대한민국 주식시장을 대표하는 코스피(KOSPI)시가 총액 상위 5개 종목인 삼성전자, SK하이닉스, LG에너지 솔루션, 삼성바이오로직스, 현대자동차의 일별 주가 데이터입니다.

수집 기간: 2020-01-01부터 현재까지 데이터를 포함하고, 이는 코로나19 이후의 급격한 시장 변동성과 최근의 경기 회복세를 모두 포함하는 충분한 데이터입니다.

데이터 항목: 각 날짜별로 시가(Open), 고가(High), 저가(Low), 종가(Close), 거래량(Volume) 정보, 즉 캔들 차트에 포함된 대부분의 정보들이 포함되어 있습니다. 특히 종가(Close) 데이터를 주된 분석 대상으로 삼아 종목간의 흐름을 파악하고 나아가서 수익 실현을 위해서 어떤 투자 전략이 필요한지 파악합니다.

데이터 특성: 수업 시간에 다룬 'Auto' 데이터셋이나 'Smarket' 데이터셋과 유사하게, 날짜별 관측치로 구성된 시계열 데이터의 특성을 가지고 있습니다. 특정 종목(LG에너지 솔루션) 등의 경우 상장일 이후부터 데이터가 존재하여 발생하는 결측치(NaN)을 포함하고 있습니다.

데이터 분석의 목적: 본 분석의 목적은 수업시간에 학습한 Statistical Learning과 Regression Analysis 기법을 실제 금융 데이터에 적용하여 종목 간의 상관관계를 도출하고 향후 주가 방향성을 예측해 보는 데 있습니다.

첫째, linear regression 모델을 구축하여 특정 대표 종목의 주가 변화를 설명하기 위해, 오늘의 정보(Open, High, Low, Close, Volume)를 모두 사용하여 내일의 Close를 예측합니다. 구축된 model의 p-value와 R-squared를 정밀하게 검정하여 모델의 유의성을 확보하는 과정을 거칩니다.

둘째, 정량적 주가 분석 수치를 바탕으로 익일 주가가 전일 대비 상승(1)할 것인지 혹은 하락(0)할 것인지를 분류 패턴을 모형화 합니다. 과제에서 다뤘던 S market 분석과 유사합니다. 수업 시간에 다룬 Cross Validation을 기반으로 Train data와 Test data를 분할하여 모델의 일반화 성능을 냉정하게 평가하고, 등락 예측에 가장 의미있게 작용하는 변수의 조합과 예측 한계를 고찰하는 것을 최종 목표로 합니다.

2. **위 데이터를 분석하기 위한 파이썬 코드를 작성하고 해당 코드 전체 동작에 대해 간략히 설명하시오.**

1. 외부 라이브러리 로드 및 초기 환경 구축: 주가 연동 API인 yfinance를 장착하고 가공을 위한 pandas 및 numpy, matplotlib.pyplot을 import 합니다. 수업 시간에 다뤘던 통계분석 전용 모듈 statsmodels.api와 통계학적 학습용 특화 패키지인 ISLP 라이브러리의 핵심 함수(load_data, ModelSpec, summarize, confusion_table)들을 로드하여 분석 환경을 선언합니다.

2. yfinance 기반 데이터 다운로드 및 구조화: 정의된 코스피 상위 5개 기업의 리스트(005930.KS, 000660.KS, 373220.KS, 207940.KS, 005380.KS)를 파라미터로 전달하여 2020-01-01부터의 가용 주가 데이터를 일단위로 긁어옵니다. 수집된 주가는 로컬 환경에 코스피_상위_5.csv 파생 파일로 영구 저장 처리됩니다. 이후 데이터프레임의 이중 헤더 구조(Price, Ticker)를 정상 인식시킨 뒤, 딕셔너리 구조체 내부에 각 종목명(Samsung, SK_Hynix 등)을 매핑하여 결측치를 정제한 독립 데이터프레임으로 파싱

및 할당합니다.

3. 기본 데이터 분석 및 기본 통계량 연산 및 시각화(데이터 구조 파악): 분할 가공된 자산별 데이터프레임을 대상으로 `head()` 명령을 수행해 상위 데이터 열을 검증하고, `describe()` 함수를 통해 각 변수별 평균값, 표준편차, 사분위수 등의 기초 통계량을 전수 산출합니다. 또한 내부 `corr()` 연산 메서드를 활용하여 자산 내의 Close와 Volume, Open 등 변수 간 선형적 결합도를 나타내는 상관관계 행렬을 도출하여 데이터의 기하학적 분포 형태를 파악합니다.
4. Linear regression 모델링 및 유의성 검정: 특정 대형주(예: 삼성전자)의 증가를 설명 모델의 타겟 변수인 output로 설정하고, 오늘의 Open, High, Low, Close, Volume을 독립변수로 설정하여 내일의 증가(Close)를 예측합니다. `ModelSpec` 개체를 생성하여 예측 변수 행렬을 통계적 포맷으로 변환한 뒤, `statsmodels`의 OLS(Ordinary Least Squares) 알고리즘을 이용해 모델 학습을 진행하고 `summarize()`를 통해 세부 회귀계수와 신뢰구간을 리포팅합니다.
5. 데이터 결측치 처리 및 다음날 등락 유도(분류 변수 생성): 금융 시계열 데이터에 무작위로 숨어있는 무한대(`inf`, `-inf`) 특성치들을 전부 제거하고 결측치 행을 `dropna()`를 통해 깨끗하게 소거합니다. 학습에 용이하도록 미래 시점인 익일의 증가 변동 흐름이 당일 증가와 비교하여 상승세를 기록했는지 여부를 계산하여 타겟 분류 마커인 이진더미 변수(`Up=1`, `Down=0`)를 생성해 냅니다.
6. Logistic, LDA, QDA를 적용: 주가의 비선형적 경계면을 유연하게 학습할 수 있는 통계 분류 모델인 이차판별분석(QDA) 알고리즘을 사용합니다. 전체 데이터를 시계열 흐름을 보존하여 Train 데이터셋과 Test 데이터셋으로 분할한 후, 학습이 완료된 QDA 모델에 테스트용 독립변수 벡터를 주입하여 예측값을 도출합니다. 최종적으로 실제 정답과 예측값 array를 비교하여 최종 분류 정확도(Accuracy)를 백분율로 산출하고, `confusion_table`을 화면에 플로팅하여 통계 양상을 확인합니다.
7. 5-Fold Cross-Validation 수행: Validation Set Approach는 데이터 분할 방식에 따라 결과가 달라질 수 있습니다. 이를 보완하기 위해 `sklearn`의 `StratifiedKFold(n_splits=5, shuffle=False)`와 `cross_val_score`를 사용하여 5-Fold Cross-Validation을 수행합니다. 시계열 데이터 특성을 고려해 `shuffle=False`로 시간 순서를 유지하며, 각 모델(Logistic, LDA, QDA)의 평균 정확도와 표준편차를 출력하고 오차 막대(error bar) 그래프로 시각화합니다.
8. ROC Curve & AUC 시각화: 정확도 외에 모델의 판별 능력을 종합적으로 평가하기 위해 `sklearn`의 `roc_curve`와 `auc`를 사용합니다. 삼성전자 종목을 대표로 Logistic, LDA, QDA 세 모델의 ROC 곡선과 AUC 값을 하나의 그래프에 겹쳐 시각화하여 모델 간 판별 성능을 직접 비교합니다.

3. 파이썬 코드를 통해 실행한 결과들을 바탕으로 데이터 분석 결과를 서술하시오.

기초 통계 분석 및 변수 간 상관성 분석 결과

1. 대한민국 주식시장의 대장주 역할을 담당하는 삼성전자(Samsung)의 주가 시계열 데이터를 기술 통계적으로 관측한 결과, 수집 기간 내 증가(Close)의 전체 평균값은 약

70,580원 선으로 집계되었습니다. 역사적 최저점은 36,473원 부근이며, 최고점은 이른바 '8만전자'를 돌파했던 시기 등을 반영하여 285,500원(수정주가 기준 반영 수치)까지 기록된 것을 확인할 수 있습니다.

2. 캔들 차트를 구성하는 핵심 지표들 간의 상관성 행렬을 살펴보면 매우 흥미로운 금융 데이터의 특성이 관찰됩니다. 당일의 종가(Close)는 당일의 고가(High), 저가(Low), 시가(Open) 변수와 모두 0.998 이상의 극도로 높은 양의 상관관계를 가집니다. 이는 일 단위 데이터 특성상 시가와 고가, 종가의 변동 범위가 동조화되어 움직이기 때문입니다. 반면, 주가의 거래량(Volume) 변수와 가격 지표(Close) 간의 상관계수는 약 0.275 수준에 머물러 자산 가격의 절대적인 크기와 일별 거래 회전을 사이에는 강한 선형 관계가 성립하지 않음을 데이터로 증명하였습니다.

Linear regression 모델 평가

주가의 내일 close가격을 예측하기 위해 오늘의 정보(Open, High, Low, Close, Volume)를 모두 사용합니다. Linear regression을 사용한 결과, 대부분의 predictor들의 p-value가 매우 의미 없는 수준으로 나타났습니다. 결과 p-value를 확인 해보면 오늘의 종가(Close)만이 유의미한 수준으로 나타났습니다. 이는 금융 데이터의 강한 자기상관성(colinerity)를 입증하는 결과입니다. P-value가 높게 나타난 Open, High, Low, Volume 변수들은 모델의 복잡도만 높이고 예측력에는 기여하지 못함을 확인하였습니다. 이는 수업 시간에 배운 변수 선택(Variable Selection)의 필요성을 시사합니다. 단순히 가격(Price level) 자체를 예측하는 모델은 전일 가격에 의존하는 경향이 강해 실제 수익 모델로는 한계가 있음을 통계적으로 확인하였습니다. 또한 이런 단편적인 정보로 "내일의 정확한 주가"를 맞추는 linear regression 모델은 주가의 변동성 때문에 p-value가 왜곡 되기 쉬움을 알 수 있습니다. 따라서 내일 주가가 오를지 내릴지 (ch04에서 다뤘던 smarket)를 예측하는 logistic regression 모델 및 LDA, QDA 모델을 적용하고자 합니다.

Logistic, LDA, QDA 모델 평가

1. 모델별 등락 예측 정확도 요약: 과거 1~2일 전의 주가 추이 (Lag1, Lag2)를 바탕으로 다음날 주가의 등락을 logistic regression, LDA, QDA로 예측한 결과, 각 모델의 정확도는 다음과 같이 산출되었습니다.

Logistic & LDA: 선형 결정을 사용하는 두 모델은 완전히 동일한 성능을 기록했습니다.

삼성전자: 43.83% | SK하이닉스: 43.18% | LG에너지솔루션: 49.76% | 삼성바이오로직스:

50.65% | 현대자동차: 46.43%

QDA: 비선형 결정을 허용하는 모델입니다.

삼성전자: 44.16% | SK하이닉스: **46.75%** | LG에너지솔루션: 47.83% | 삼성바이오로직스:

50.33% | 현대자동차: **50.00%**

2. 가장 우수한 성능을 보인 모델 및 결론: 전체 수치 중 가장 높은 정확도를 기록한 모델은 삼성바이오로직스를 대상으로 한 로지스틱 회귀 및 LDA 모델(50.65%)이었습니다. 삼성전자, SK하이닉스, 현대자동차 3개 종목에서는 선형 모델보다 비선형적 경계를 학습하는 QDA 모델이 상대적으로 더 우수한 성능을 보여주었습니다. (예: SK하이닉스 선형 43.18% → QDA 46.75%로 향상) 하지만 세 가지 모델 모두 최종 예측 정확도가 동전 던지기 확률(50%) 안팎에 머물렀습니다. 특히 삼성전자 QDA의 경우 데이터의 과도한 노이즈로 인해

테스트 기간 전체를 '하락'으로만 편향되게 예측하는 한계를 보였습니다. 결과적으로 과거의 단기 주가 흐름만으로는 미래 주가를 유의미하게 맞추기 어렵다는 주식시장의 '임의 보행(Random Walk) 특성'을 실증 데이터로 확인하였습니다.

5-Fold Cross-Validation 결과

Validation Set Approach 결과와의 비교 검증 차원에서 5-Fold CV를 추가 적용한 결과, 세 모델 모두 평균 정확도가 50% 전후로 일관되게 나타났습니다. 표준편차가 약 0.02~0.05 수준으로 비교적 안정적이어서, 단순 분할 방식에서의 운에 의한 결과가 아닌 변수 자체의 예측력 한계가 주된 원인임을 재확인하였습니다. 이는 단기 수익률 Lag 변수만으로는 주가 방향성 예측에 근본적인 한계가 있다는 효율적 시장 가설(EMH)과도 부합하는 결과입니다.

ROC Curve & AUC 결과

삼성전자 종목을 대표로 산출한 ROC Curve에서 Logistic, LDA, QDA 세 모델의 AUC 값이 모두 0.50~0.54 수준으로, 대각선(무작위 분류기 기준선)에 매우 근접하는 결과를 보였습니다. 이는 정확도 수치와 완전히 일치하는 결과로서, 전일 수익률 정보(Lag1, Lag2)만으로는 방향성을 통계적으로 유의미하게 판별하기 어려우며, 향후 거시경제 지표나 투자 심리 지수 등 추가 변수 도입이 필요함을 시사합니다.

4. 위 파이썬 코드에서, 수업시간에 실습한 library code 및 내용들이 어떻게 활용되고 반영되었는지 설명하시오.

본 과제의 코드는 수업 시간에 실습한 Smarket 데이터셋의 주가 방향성 예측 파이프라인과 라이브러리 활용 문법을 활용하여 국내 코스피(KOSPI) 시장에 확장 적용한 결과물입니다. 구체적인 일치 사항은 다음과 같습니다.

동일한 예측 변수(Lag1, Lag2) 및 데이터 분할(Validation) 적용

Smarket 실습에서 과거 주가 수익률 지표인 Lag1, Lag2를 핵심 독립변수로 설정하고 일의 상승/하락 방향성인 Direction을 타겟 변수로 삼았던 논리 구조를 그대로 적용했습니다. 실습 파일에서 특정 연도(2005년)를 기준으로 Train과 Test 데이터를 시계열 순서에 맞춰 분할했던 것과 동일하게, 본 코드에서도 무작위 셔플링 대신 `iloc[:train_size]` 기반의 전방부 80%를 훈련용으로, 후방부 20%를 검증용으로 순차 분할하는 시계열 검증 방법론을 동일하게 고수했습니다.

로지스틱 회귀(GLM) 모델링 및 예측 파이프라인의 일치

일반적인 머신러닝 패키지 대신, 수업에서 배운 통계 전문 모듈 `statsmodels.api(sm)`의 `sm.GLM()` 함수를 사용하고 이진 분류를 위한 속성인 `family=sm.families.Binomial()` 모델을 선언하는 문법을 동일하게 구현했습니다. 모델 적합 후 도출된 확률값(`probs`)을 `np.where(probs > 0.5, 1, 0)`를 통해 임계값 0.5 기준으로 이진 클래스(1과 0)로 변환하고, `np.mean(preds == data['y_test'])`로 테스트 정확도를 산출하는 연산 공식 역시 실습 코드의 방식을 그대로 따랐습니다.

LDA, QDA 알고리즘 구현 방식의 일치

Smarket 교재 실습 4장의 핵심이었던 선형판별분석(LDA)과 이차판별분석(QDA)의 구현을 위해 `sklearn.discriminant_analysis` 패키지에서 객체를 소환하는 아키텍처를 그대로 가져

왔습니다. 학습을 진행하는 `.fit(X_train, y_train)` 메서드와 테스트 데이터를 통해 라벨을 직접 도출하는 `.predict(X_test)` 메서드의 연계 구동 방식을 완벽히 동일하게 매핑하여 모델을 실전 배치했습니다.

ISLP 패키지 특화 인터페이스의 전수 활용

절편(Intercept) 항을 수식에 포함하기 위해 디자인 매트릭스를 빌드하는 `ModelSpec(X_cols)` 개체의 선언과 `.fit_transform()`, `.transform()`의 활용 구조가 일치합니다. 로지스틱 회귀의 통계적 유의성(coef, p-value 등)을 테이블 형태로 정돈하여 출력해 주는 `summarize()` 함수를 대표 종목(삼성전자) 분석에 동일하게 배치했습니다.

예측 오류의 양상을 행렬로 시각화해 주는 `confusion_table()` 함수를 호출하여 Truth와 Predicted 간의 크로스 매트릭스를 뽑아내는 출력 포맷까지 실습 파일의 문법을 그대로 재현했습니다.

Resampling Methods: 5-Fold Cross-Validation 적용

Resampling Methods를 코드에 직접 구현하였습니다. 기존 Validation Set Approach(iloc 기반 80/20 순차 분할)에 더하여, sklearn의 `StratifiedKFold(n_splits=5, shuffle=False)`와 `cross_val_score`를 사용하는 5-Fold CV를 추가 적용했습니다. `shuffle=False` 설정으로 시계열 데이터의 시간 순서를 보존하였으며, 이는 수업에서 강조한 "시계열 데이터에서의 데이터 누수(data leakage) 방지" 원칙을 실제로 적용한 부분입니다. 또한 평균 정확도와 표준편차를 함께 보고함으로써 수업에서 다룬 Bias-Variance Tradeoff 개념과 모델 일반화 성능 평가 방법론을 실전 데이터로 검증하였습니다.